

概率论与数理统计知识点整理

KujoStar-hmc

2022 年 1 月 5 日

前言

作者于 2022-2023 学年秋季学期上了唐宏岩老师的概率论与数理统计课程，一学期颇受折磨，但是唐老师教学水平高超、教学内容丰富，若是用心理解钻研，确实会学到不少东西。前几天刚刚考完期末考试，想着可以趁着得闲将一学期所学知识精简整理，希望对以后选修概率论与数理统计课程（不局限于唐老师）的同学有一点微薄的帮助。

除了本人笔记外，此文档也参考了 lambda 的听课笔记进行整理归纳，特此致谢。

一、常用的计算恒等式

指数函数的级数求和表示

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$$

与二项分布相关的常见积分

$$\int_{-\infty}^{+\infty} e^{-\frac{x^2+a^2}{2}} dx = \sqrt{2\pi} e^{-\frac{a^2}{2}}$$
$$\int_{-\infty}^{+\infty} e^{-\frac{(x+a)^2}{2\sigma^2}} dx = \sqrt{2\pi}\sigma$$

与 Gamma 函数相关的计算式

$$\int_0^1 u^{a-1}(1-u)^{b-1} du = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}, \Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$$

组合数相关恒等式

$$k \binom{n}{k} = n \binom{n-1}{k-1}$$

$$k^2 \binom{n}{k} = n \binom{n-1}{k-1} + n(n-1) \binom{n-2}{k-2}$$

$$\sum_{k=0}^n \binom{n}{k} p^k q^{n-k} = (p+q)^n$$

另外，打好微积分和线性代数的基础、掌握这两门数学基础课中的一些思想对概统的学习非常重要。

二、事件的概率

1. 事件和与差的概率

$$P(A+B) = P(A) + P(B) - P(AB), P(A-B) = P(A) - P(AB)$$

对于事件和的概率推广到一般性，我们有

$$P\left(\sum_{i=1}^n A_i\right) = \sum_{r=1}^n (-1)^{r+1} \sum_{i_1 < i_2 < \dots < i_r}^{i_k \in \{1, \dots, n\}} P\left(\prod_{k=1}^r A_{i_k}\right)$$

2. 条件概率

$$P(A|B) = \frac{P(AB)}{P(B)}, P(AB) = P(B)P(A|B)$$

$$P(B|A) = \frac{P(B)P(A|B)}{P(A)}$$

$$P(A) = P(B)P(A|B) + P(\overline{B})P(A|\overline{B})$$

3. Bayes 公式

设 $B_i, i = 1, 2, \dots, n$ 为全事件 Ω 的一个划分，则有求解条件概率的贝叶斯公式：

$$\forall i, P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$$

三、随机变量及其分布

如无特殊说明，本节涉及的 $F(x)$ 均表示随机变量 X 的 cdf, $f(x)$ 表示随机变量 X 的 pmf/pdf, $E(X)$ 表示随机变量 X 的期望, $Var(X)$ 表示随机变量 X 的方差。

首先，我们有 $\sum_{i=1}^{\infty} f(x) = 1$ (离散) 或 $\int_{\mathbb{R}} f(x)dx = 1$ (连续)。这是由 pmf 和 pdf 的定义保证的。

1. 常见的离散分布

Bernouli 分布 (两点分布)

若随机变量 X 满足

$$X = \begin{cases} 1, & p \\ 0, & 1-p \end{cases}, p \in (0, 1)$$

则称 X 服从概率为 p 的 Bernouli 分布, 记作

$$X \sim B(p)$$

我们有

$$E(X) = p, \text{Var}(X) = p(1-p)$$

二项分布

二项分布其实说明了 n 次独立的 Bernouli 实验的成功次数。记 X 为这一次数, 我们有

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, k = 0, 1, \dots, n$$

则 X 服从二项分布, 记作

$$X \sim B(n, p)$$

我们有

$$E(X) = np, \text{Var}(X) = np(1-p)$$

Poisson 分布

若随机变量 X 满足

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \lambda > 0, k \in \mathbb{N}$$

则称 X 服从参数为 λ 的 Poisson 分布, 记作

$$X \sim P(\lambda)$$

我们有

$$E(X) = \text{Var}(X) = \lambda$$

Remark: 二项分布可以用 Poisson 分布来近似。具体来说, 若 $X \sim B(n, p)$, 则可以近似认为 $X \sim P(\lambda)$, 其中参数 $\lambda = np$ 。当 p 很小, n 很大, λ 不太大时, 近似的效果很好, 其误差上限为 $\min\{p, np^2\}$ 。

2. 常见的连续分布

均匀分布

若随机变量 X 的 pdf 为

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & \text{otherwise} \end{cases}$$

则称 X 服从区间 $[a, b]$ 上的均匀分布, 记作

$$X \sim U(a, b)$$

我们有

$$E(X) = \frac{a+b}{2}, Var(X) = \frac{1}{12}(b-a)^2$$

Remark: $X \sim U(0, 1)$ 通常称为随机数。

正态分布

若随机变量 X 的 pdf 为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in \mathbb{R}$$

则称 X 服从正态分布, 记作

$$X \sim N(\mu, \sigma^2)$$

我们有

$$E(X) = \mu, Var(X) = \sigma^2$$

Remark1: $N(0, 1)$ 称为标准正态分布。

Remark2: 正态分布标准化:

$$X \sim N(\mu, \sigma^2) \Leftrightarrow Y = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

指数分布

若随机变量 X 的 pdf 为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}, \lambda > 0$$

则称 X 服从指数分布, 记作

$$X \sim Exp(\lambda)$$

我们有

$$E(X) = \frac{1}{\lambda}, Var(X) = \frac{1}{\lambda^2}$$

Remark: 此时随机变量 X 的 cdf 为

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Beta 分布

若随机变量 X 的 pdf 为

$$f(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1}(1-x)^{b-1}, 0 \leq x \leq 1$$

其中

$$\Gamma(x) = \int_0^{+\infty} e^{-t} t^{x-1} dt$$

则称 X 服从 Beta 分布, 记作

$$X \sim \text{Beta}(a, b)$$

我们有

$$E(X) = \frac{a}{a+b}, \text{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)}$$

Remark: Gamma 函数有如下性质:

$$\Gamma(x+1) = x\Gamma(x)$$

利用 Gamma 函数的定义以及分部积分法易证。

3. 随机变量的函数

设 X 为一个随机变量, $g(x)$ 为在 X 取值范围内有定义的函数, 若随机变量 $Y = g(X)$, 则称 Y 为随机变量 X 的函数。

pdf 公式推导

令 X 为连续型随机变量, 其 pdf 为 $f(x)$, 假设 $g(x)$ 为严格单调可微函数, 则 $Y = g(X)$ 的 pdf 为

$$f_Y(y) = \begin{cases} f(h(y))h'(y), & \alpha \leq y \leq \beta \\ 0, & \text{otherwise} \end{cases}$$

其中

$$\alpha = \min\{g(-\infty), g(+\infty)\}, \beta = \max\{g(-\infty), g(+\infty)\}, h(x) = g^{-1}(x)$$

利用分布函数的定义易证。

典例

对数正态分布的概率密度函数。设随机变量 $Y > 0$, $X = \ln Y \sim N(\mu, \sigma^2)$, 则 Y 的 pdf 为

$$f(y) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma y} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}, & y > 0 \\ 0, & y \leq 0 \end{cases}$$

四、联合分布

本节研究的对象为随机向量：

$$(X_1, \dots, X_n), \Omega \rightarrow \mathbb{R}^n$$

随机向量的每个分量都是同一个 Ω 上的随机变量。大部分时候主要研究二元分布，此时的随机向量记为 (X, Y) ，联合 cdf 记为 $F(x, y)$ ，联合 pdf 记为 $f(x, y)$ 。

设 n 元分布的 pdf 为 $f(x_1, x_2, \dots, x_n)$ ，由概率的定义，我们首先有

$$\sum_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = 1$$

或者

$$\int_{\mathbb{R}^n} f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n = 1$$

1. 常见的联合分布

多项分布

设某个随机试验有 n 个互斥的可能结果： A_1, A_2, \dots, A_n ， $\{A_i\}$ 是全事件 Ω 的一个划分， A_i 发生的概率是 p_i ， A_i 出现的次数为 X_i 。设 $\sum_{i=1}^n k_i = N$ ， N 为总实验次数，则我们有

$$P(X_1 = k_1, \dots, X_n = k_n) = \binom{N}{k_1, \dots, k_n} \prod_{i=1}^n p_i^{k_i}$$

其中

$$\binom{N}{k_1, \dots, k_n} = \frac{N!}{\prod_{i=1}^n k_i!}$$

二元均匀分布

pdf 为

$$f(x, y) = \begin{cases} \frac{1}{(b-a)(d-c)}, & (x, y) \in (a, b) \times (c, d) \\ 0, & \text{otherwise} \end{cases}$$

Remark：二元分布又被称为矩形分布。

二元正态分布

$(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，其中 $|\rho| < 1$ ，则 (X, Y) 服从二元正态分布，其联合 pdf 为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2} \frac{1}{\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\left(\frac{x-\mu_1}{\sigma_1} \right)^2 + \left(\frac{y-\mu_2}{\sigma_2} \right)^2 - 2\rho \frac{x-\mu_1}{\sigma_1} \frac{y-\mu_2}{\sigma_2} \right] \right\}$$

2. 边际分布

边际分布的 cdf

我们考虑随机向量 (X_1, X_2, \dots, X_n) , 则我们定义 X_i 的边际 cdf:

$$F_i(x) := P(X_i \leq x) = P(X_i \leq x, \forall j \neq i, X_j \in \mathbb{R})$$

一般研究二元分布 (X, Y) , 设联合 cdf 为 $F(x, y)$, 则我们有 X 的边际 cdf 为

$$\begin{aligned} F_X(x) &:= P(X \leq x) \\ &= P(X \leq x, -\infty < Y < +\infty) \\ &= \lim_{y \rightarrow +\infty} P(X \leq x, -\infty < Y \leq y) \\ &= \lim_{y \rightarrow +\infty} F(x, y) \end{aligned}$$

Y 的边际 cdf 可以类似得到。

边际分布的 pdf

边际分布描述了随即向量每个分量单独的分布情况。此处以连续型二元分布 (X, Y) 为研究的对象。设 (X, Y) 的联合 pdf 为 $f(x, y)$, 由上面对边际 cdf 的讨论, 我们有

$$F_X(x) = \lim_{y \rightarrow +\infty} F(x, y) = \int_{-\infty}^x \int_{\mathbb{R}} f(t, y) dy dt$$

我们熟知, 随机变量 X 的 cdf $F(x)$ 与 pdf $f(x)$ 之间有如下关系:

$$F'(x) = f(x)$$

则对上面得到的式子对 x 求导, 我们有

$$f_X(x) = \int_{\mathbb{R}} f(x, y) dy$$

这就是 X 的边际 pdf。同理我们得到 Y 的边际 pdf 为

$$f_Y(y) = \int_{\mathbb{R}} f(x, y) dx$$

典例

我们设随机向量 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则我们有如下结论:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}, x \in \mathbb{R}$$

也即

$$X \sim N(\mu_1, \sigma_1^2)$$

同理, 我们可以得到

$$Y \sim N(\mu_2, \sigma_2^2)$$

结论的推导对二元正态分布的联合 pdf 直接单侧积分即可, 读者可以检验自己的微积分水平(逃)。

Remark: 联合分布可以确定边际分布, 但是反之未必成立。

3. 条件分布

条件分布描述了在一些分量的值已经确定的情况下，随机向量中另外的分量的分布情况。绝大部分时候，我们仅仅以二元随机向量 (X, Y) 为研究对象。

离散型随机向量

我们设

$$P(X = a_i, Y = b_j) = p_{ij}, \sum_{i,j} p_{ij} = 1$$

则我们有

$$P(X = a_i | Y = b_j) = \frac{P(X = a_i, Y = b_j)}{P(Y = b_j)} = \frac{p_{ij}}{\sum_k p_{kj}}$$

Remark:

$$\sum_i P(X = a_i | Y = b_j) = 1$$

连续型随机向量

我们设 (X, Y) 的 pdf 为 $f(x, y)$ ，则我们有

$$\begin{aligned} & P(X \leq x | y \leq Y \leq y + dy) \\ &= \frac{P(X \leq x, y \leq Y \leq y + dy)}{P(y \leq Y \leq y + dy)} \\ &= \frac{\int_{-\infty}^x \left(\int_y^{y+dy} f(s, t) dt \right) ds}{\int_y^{y+dy} f_Y(s) ds} \end{aligned}$$

对 x 求导可以得到 X 此时的条件概率密度为

$$f_X(x | y \leq Y \leq y + dy) = \frac{\int_y^{y+dy} f(x, t) dt}{\int_y^{y+dy} f_Y(s) ds}$$

令 $dy \rightarrow 0$ ，我们可以得到

$$f_X(x | Y = y) = \frac{f(x, y)}{f_Y(y)}$$

于是可以定义 X 的条件密度函数：

$$f_X(x | y) := \frac{f(x, y)}{f_Y(y)}$$

类似地，我们有

$$f_Y(y | x) := \frac{f(x, y)}{f_X(x)}$$

典例

设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则根据条件分布的定义, 简单计算可得

$$f_Y(y|x) = \frac{1}{\sqrt{2\pi}\sigma_2} \frac{1}{\sqrt{1-\rho^2}} \exp \left\{ -\frac{\left[y - \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x - \mu_1) \right) \right]^2}{2(1-\rho^2)\sigma_2^2} \right\}$$

也即当 $X = x$ 时, 我们得到 Y 的分布:

$$Y \sim N \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x - \mu_1), (1 - \rho^2) \sigma_2^2 \right)$$

4. 条件分布下的全概率公式

X 离散, Y 离散

$$P(X = x_i) = \sum_j P(X = x_i | Y = y_j) P(Y = y_j)$$

X 离散, Y 连续

$$P(X = x_i) = \int_{\mathbb{R}} P(X = x_i | Y = y) f_Y(y) dy$$

X 连续, Y 离散

$$f_X(x) = \sum_i f_X(x | y_i) P(Y = y_i)$$

X 连续, Y 连续

$$f_X(x) = \int_{\mathbb{R}} f(x, y) dy = \int_{\mathbb{R}} f_X(x | y) f_Y(y) dy$$

5. 条件分布下的 Bayes 公式

X 离散, Y 离散

$$P(Y = y_i | X = x_i) = \frac{P(X = x_i | Y = y_i) P(Y = y_i)}{P(X = x_i)} = \frac{P(X = x_i | Y = y_i) P(Y = y_i)}{\sum_j P(X = x_i | Y = y_j) P(Y = y_j)}$$

X 离散, Y 连续

$$P(Y = y | X = x_i) = \frac{P(X = x_i | Y = y) f_Y(y)}{P(X = x_i)} = \frac{P(X = x_i | Y = y) f_Y(y)}{\int_{\mathbb{R}} P(X = x_i | Y = y) f_Y(y) dy}$$

X 连续, Y 离散

$$P(Y = y_i | X = x) = \frac{f_X(x|y_i)P(Y = y_i)}{f_X(x)} = \frac{f_X(x|y_i)P(Y = y_i)}{\sum_i f_X(x|y_i)P(Y = y_i)}$$

X 连续, Y 连续

$$f_Y(y|x) = \frac{f_X(x|y)f_Y(y)}{f_X(x)} = \frac{f_X(x|y)f_Y(y)}{\int_{\mathbb{R}} f_X(x|y)f_Y(y)dy}$$

6. 随机向量分量之间的独立性

设随机向量 (X, Y) 的 cdf 为 $F(x, y)$, 若 $F(x, y) = F_X(x)F_Y(y)$, 则称 X, Y 独立。

Remark: X, Y 独立 $\Leftrightarrow f(x, y) = f_X(x)f_Y(y), \forall x, y \in \mathbb{R}$

五、多个随机变量的函数

设有 n 个随机变量 $X_i, i = 1, 2, \dots, n$, 函数 $g(x_1, x_2, \dots, x_n)$ 为 n 元函数, 设有随机变量 Y , 满足 $Y = g(X_1, X_2, \dots, X_n)$, 则称 Y 为随机变量 X_1, X_2, \dots, X_n 的函数。本节主要研究 Y 的相关性质。

1. 随机变量的和的分布

相互独立的二项分布的和

设 $X_i \sim B(n_i, p), i = 1, 2, X_1, X_2$ 独立, 设 $Y = X_1 + X_2$, 则有结论:

$$Y \sim B(n_1 + n_2, p)$$

Remark: 利用二项分布的概率表达式, 对其中一个变量进行求和即可。也即利用

$$P(Y = k) = P(X_1 + X_2 = k) = \sum_{k_1=0}^k P(X_1 = k_1)P(X_2 = k - k_1)$$

相互独立的 Poisson 分布的和

设 $X_i \sim P(\lambda_i), i = 1, 2, X_1, X_2$ 独立, 设 $Y = X_1 + X_2$, 则有结论:

$$Y \sim P(\lambda_1 + \lambda_2)$$

二元正态分布分量的和

设 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则有

$$X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$$

2. 随机变量的商的分布

设 (X_1, X_2) 有联合 pdf $f(x_1, x_2)$, 设 $Y = \frac{X_2}{X_1}$, 其中 $X_1 > 0$, 研究 Y 的分布。
根据定义, 对 $\forall y$, 我们有

$$\begin{aligned} & P(Y \leq y) \\ &= P\left(\frac{X_2}{X_1} \leq y\right) \\ &= P(X_2 \leq yX_1) \\ &= \iint_{x_2 \leq yx_1} f(x_1, x_2) dx_1 dx_2 \\ &= \int_0^{+\infty} \left(\int_{-\infty}^{yx_1} f(x_1, x_2) dx_2 \right) dx_1 \\ &\stackrel{x_2=tx_1}{=} \int_{-\infty}^y \left(\int_0^{+\infty} x_1 f(x_1, x_1 t) dx_1 \right) dt \end{aligned}$$

对 y 求导, 得到 Y 的 pdf 为

$$l(y) = \int_0^{+\infty} x_1 f(x_1, x_1 y) dx_1$$

3. 密度函数变换法

设随机向量 (X_1, X_2) 有联合 pdf $f(x_1, x_2)$, 设 $(Y_1, Y_2) = (g_1(X_1, X_2), g_2(X_1, X_2))$, 且该变换可逆可微, 也即 $\exists h_1, h_2$, 使得 $(X_1, X_2) = (h_1(Y_1, Y_2), h_2(Y_1, Y_2))$, 则 (Y_1, Y_2) 的联合 pdf 为

$$f(h_1(y_1, y_2), h_2(y_1, y_2)) |\det J|$$

其中矩阵 J 为变换的 Jacobi 矩阵, 也即

$$J = \frac{\partial(h_1, h_2)}{\partial(y_1, y_2)} = \begin{bmatrix} \frac{\partial h_1}{\partial y_1} & \frac{\partial h_1}{\partial y_2} \\ \frac{\partial h_2}{\partial y_1} & \frac{\partial h_2}{\partial y_2} \end{bmatrix}$$

典例

设 (X_1, X_2) 的 pdf 为 $f(x_1, x_2)$, 利用密度函数变换法求 $Y = X_1 + X_2$ 的 pdf。
我们令

$$Y = X_1 + X_2, Z = X_1$$

则有逆变换为

$$X_1 = Z, X_2 = Y - Z$$

对应的 $\det J$ 为

$$\begin{vmatrix} 0 & 1 \\ 1 & -1 \end{vmatrix} = -1$$

则 Y, Z 的联合 pdf 为

$$l(y, z) = f(z, y - z) |-1| = f(z, y - z)$$

Y 的 pdf 为

$$l_Y(y) = \int_{\mathbb{R}} l(y, z) dz = \int_{\mathbb{R}} f(z, y - z) dz$$

Remark: 若 X_1, X_2 独立, 则有

$$l_Y(y) = \int_{\mathbb{R}} f_{X_1}(z) f_{X_2}(y - z) dz$$

这是卷积和积分变换的一种直观解释。

4. 次序统计量

设 $X_i (i = 1, 2, \dots, n)$ 为来自同一总体的样本, 总体 cdf 为 $F(x)$, 总体 pdf 为 $f(x)$, $X_{(k)}$ 表示从小到大排列后次序为 k 的随机变量, 例如 $X_{(1)}$ 表示 $\min\{X_1, X_2, \dots, X_n\}$, $X_{(n)}$ 表示 $\max\{X_1, X_2, \dots, X_n\}$ 。

单个次序统计量的分布

次序统计量 $X_{(k)}$ 的 pdf 为

$$f_k(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x)$$

两个次序统计量的联合分布

任意两个次序统计量 $X_{(i)}, X_{(j)} (i < j)$ 的联合 pdf 为

$$f_{i,j}(x, y) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(x)]^{i-1} [F(y) - F(x)]^{j-i-1} [1-F(y)]^{n-j} f(x) f(y), x < y$$

以上结论均采用 pdf 的极限形式进行证明, 可以参考作者的知乎专栏: [前往奇妙世界](#)